

Checklist de nettoyage de données

Module 3 — Transformer Claude en Data Analyst personnel

À utiliser avant toute analyse, sur n'importe quel fichier reçu d'un client ou d'un collègue — même quand le fichier « a l'air propre » à l'œil. Cochez chaque case au fur et à mesure.

Étape 1 — Diagnostic (avant toute correction)

- ☐ Doublons stricts : combien de lignes sont strictement identiques à une autre ligne ?
- ☐ Valeurs manquantes : combien de cellules vides, par colonne ?
- ☐ Formats incohérents (texte) : une même valeur écrite de plusieurs façons (casse, espaces) ?
- ☐ Formats incohérents (dates) : plusieurs formats coexistent-ils dans la même colonne ?
- ☐ Valeurs aberrantes : des valeurs numériques anormalement grandes, négatives ou incohérentes ?

Étape 2 — Correction (une étape à la fois)

- ☐ Suppression des doublons stricts confirmée (comparer le nombre de lignes avant/après)
- ☐ Valeurs manquantes traitées avec une méthode choisie et documentée
- ☐ Formats texte standardisés (une seule écriture par valeur réelle)
- ☐ Dates uniformisées sur un seul format, en vrai type « date »
- ☐ Valeurs aberrantes corrigées ou exclues, colonnes calculées recalculées en conséquence

À retenir

Un nettoyage qu'on ne peut pas expliquer à son client en 2 minutes n'est pas un nettoyage fiable — même s'il « a marché ». Documentez toujours votre méthode, pas seulement le résultat.

Checklist de nettoyage de données

Vérification finale, documentation, exemple DELTA Distribution

Étape 3 — Vérification finale (ne jamais sauter)

- ☐ Nombre de lignes final noté et expliqué (combien de lignes supprimées, et pourquoi)
- ☐ Zéro valeur manquante restante confirmée colonne par colonne
- ☐ Zéro doublon restant confirmé
- ☐ Les valeurs catégorielles (région, canal...) listées une par une : plus aucune variante
- ☐ Les min/max de chaque colonne numérique passés en revue pour repérer une dernière anomalie

Étape 4 — Documenter le nettoyage

- Le nombre de lignes avant et après nettoyage.
- La méthode choisie pour les valeurs manquantes, et pourquoi celle-là plutôt qu'une autre.
- Les valeurs aberrantes trouvées et comment elles ont été traitées.

Exemple rempli — dataset DELTA Distribution (Module 3)

Étape	Constat	Action
Doublons	10 lignes strictement dupliquées	Supprimées — 310 → 300 lignes
Valeurs manquantes	5 sur quantité, 10 sur prix unitaire	Imputées par médiane produit/région/canal
Formats texte	4 variantes de « Nord »	Standardisées vers « Nord »
Dates	2 formats mélangés (JJ/MM/AAAA et AAAA-MM-JJ)	Uniformisées en type date unique
Valeurs aberrantes	Quantité 99999, prix négatif, prix ×100	Corrigées, montant total recalculé

Voir le nettoyage complet et commenté dans 06-exercices/exercice-guide-solution.md.